

# Derinlik Bilgisi Kullanılarak İnsan Hareketlerinin Tanınması

## Recognition of Human Actions By using Depth Information

Ali Seydi Keçeli, Ahmet Burak Can  
Bilgisayar Mühendisliği Bölümü  
Hacettepe Üniversitesi  
Ankara, Türkiye  
{aliseydi, abc}@cs.hacettepe.edu.tr

**Özetçe**—Derinlik algılayıcılardan elde edilen 3. boyut bilgisinin insan hareketinin tanınmasında kullanılması son yıllarda önem kazanmaya başlamıştır. Derinlik bilgisi, bazı uygulamalarda tanıma duyarlılığını artırmaktadır. Bu çalışmada, Microsoft Kinect RGBD algılayıcıdan elde edilen bir insan modeli üzerinde 10 farklı insan hareketi tanınmaya çalışılmıştır. Eklemler arasındaki açılar ve eklemlerin 3 koordinat eksenindeki yer değiştirmesi öznitelik olarak alınmıştır. Hareketler, random forest ve support vector machine yöntemleri kullanılarak sınıflandırılmış ve random forest yöntemi ile %96 kadar sınıflandırma başarıları sağlanmıştır.

**Anahtar Kelimeler** — Hareket tanıma, Microsoft Kinect, support vector machine, random forest.

**Abstract**— Usage of 3. dimension information obtained from depth sensors in human action recognition become important recently. Depth information can increase recognition accuracy in some applications. In this study, 10 different human actions are tried to recognize on a human model derived from Microsoft Kinect RGBD sensor. Angles between joints and displacement of joints on 3 koordinat axes are used as features. Actions are classified with the random forest and support vector machine approaches and 96% classification accuracy is obtained with the random forest approach.

**Keywords** — Action recognition, Microsoft Kinect, support vector machine, random forest.

### I. GİRİŞ

3 boyutlu derinlik algılayıcıların, insan hareketlerinin tanınması, ortam haritasının çıkarılması gibi alanlarda kullanımı günümüzde gittikçe yaygınlaşmaktadır. Robot uygulamalarında, robotun bulunduğu ortamın haritasının gerçek zamanlı çıkarılmasında derinlik algılayıcıları ile başarılı sonuçlar elde edilebilmektedir. Özellikle günümüz oyun konsollarındaki etkileşimli oyunlarda, insan hareketlerinin tanınarak oyunun yönlendirilmesi konusunda bir tür derinlik algılayıcısı olan RGBD algılayıcılar sıkça kullanılmaktadır.

Microsoft Kinect sistemi [2,7], derinlik haritası üzerinden 20 eklemlilik iskelet modeli oluşturma özelliğine sahip bir RGBD algılayıcıdır. Kinect sistemi, silüete ilişkin iskelet çıkarma ve takibini kızıl ötesi ışın yayan bir projektör yardımıyla gerçekleştirmektedir. Cihaz tarafından yayılan ışınlar CMOS algılayıcı tarafından toplanmakta ve ortama ilişkin bir derinlik haritası oluşturulmaktadır. Bu yöntemin en büyük avantajı, hesaplama maliyetinin düşük olması ve gerçek zamanlı uygulamalar geliştirilmesine olanak sağlamasıdır. Derinlik haritası, çoklu kamera sistemleri kullanarak da elde edilebilir, fakat bu işlemin hesaplama maliyeti oldukça fazladır.

RGBD algılayıcılar ile hareket tanımda ilk adım, derinlik haritasındaki insan silüetlerinin çıkarılmasıdır. Bu amaçla, Xia ve diğerlerinin çalışmasında [2], önce Microsoft Kinect RGBD algılayıcıdan elde edilen derinlik haritası üzerinde median filtrelemesi yapılarak gürültü giderilmiştir. Derinlik haritasından Canny algoritması [14] ile kenar bilgileri elde edilmiştir. Bir kafa şablonu, ikili kenar maskesi üzerinde gezdirilerek 2 boyutlu Chamfer karşılaştırılması [13] yapılmıştır. Belli bir eşiği aşan noktalar için, o derinlikte olabilecek tahmini bir insan kafasının boyu hesaplanmış ve insan silüeti bulunmaya çalışılmıştır. Luber ve diğerlerinin [9] çalışmasında, HOG (*Histogram of Oriented Gradients*) [10] yaklaşımı, derinlik bilgisi üzerinde uygulanmıştır. Bu şekilde kişi tespit edildikten sonra takip işleminde MHT (*Multi-hypothesis Tracker*) yöntemi [11] kullanılmıştır. Li ve diğerleri [5], derinlik haritasının kartezyen düzlemler  $(x-y, x-z, y-z)$  üzerinde projeksiyonunu almıştır. Bu projeksiyonların kenarları çıkartılıp, elde edilen kenar noktalarına en yakın derinlik haritasındaki 3 boyutlu noktalar seçilmiştir. Seçilen bu noktalar poz tanımlamak için kullanılmıştır. Bir çizelge ile hareketler, bir poz dizisi ve bu pozlar arasındaki geçiş olasılıklarını belirten bir geçiş matrisi olarak tanımlanmıştır. Gözlenen değerler belirli pozlara atanır ve sonra bu pozları kullanarak hareket tanınır. Sung ve diğerlerinin [1] çalışmasında, derinlik haritasından gövde duruşu, el konumu ve hareket bilgisi ile ilgili öznitelikler çıkarılarak insan hareketleri tanınmaya çalışılmıştır. Bu öznitelikler, PrimeSense [6] kütüphanesi ile oluşturulan 15 eklemlilik iskelet modelinden çıkarılmıştır. Hareketi tanımda hiyerarşik bir Hidden Markov Model (HMM) kullanılarak, elde edilen poz bilgilerinden birinci katmanda alt aktivite tanınmıştır. Üst katmanda ise alt aktiviteleri kullanarak daha karmaşık aktiviteler tanınmıştır. Doliotis ve diğerleri [4], el hareketlerinin takibi için derinlik bilgisinin kullanıldığı bir yöntem önermişlerdir. Deri tanıma için RGB değerlerden oluşan bir histogram kullanılmıştır. Hareket tespit etmede, her çerçevedeki gri seviye piksel değerlerin bir sonraki çerçeveden farkı kullanılmıştır. Bu bilgilerden elde edilen skorların toplamının en fazla değeri olduğu alt pencereler el konumu olarak tahmin edilmiştir. Derinlik bilgisi de kullanılarak, çerçevedeki en büyük 5 bileşenden en yakın olan el konumu olarak seçilmiştir. El konumuna ilişkin konum bilgileri *Dynamic Time Warping* (DTW) [19] algoritmasında kullanılarak el hareketleri tanınmaya çalışılmıştır.

Popa ve diğerleri [7], Kinect RGBD algılayıcı ve kamerayı birlikte kullanarak alışverişle ilgili insan hareketlerini tanımlamıştır. Önce kamerada arka plan çıkarma ile, RGBD algılayıcıda derinlik haritası kullanılarak kişi silüeti elde edilmektedir. Kameradan elde edilen silüet üzerinde hesaplanan moment değerleri [8] öznitelik olarak kullanılmaktadır. Ard arda gelen silüet görüntülerinin farkları alınarak bir hareket matrisi oluşturulmuştur. RGBD algılayıcı ile de, derinlik haritası kullanılarak, kişinin uzaklaşma ve yaklaşma bilgisi ayrı bir matrise kaydedilmiştir. Tanıma işlemi için Support Vector Machine (SVM)[20], K-nearest neighbor(K-NN) [20], LDC[21] ve

HMM algoritmaları kullanılmıştır. En iyi sonuçlar LDC sınıflandırıcısı ile elde edilmiştir.

Raptis ve diğerlerinin makalesinde [18], Kinect RGBD algılayıcı ve Shotton ve diğerlerinin [3] iskelet modelinden elde edilen nitelikler kullanılarak dans figürleri tanınmaya çalışılmıştır. Gövdeye ilişkin eklemlerin konum değerleri üzerinde PCA algoritması [12] uygulanmıştır. Eklemler arası açılar ve uzaklıklara dayalı öznelitlikler üzerinde kademeli bir sınıflayıcı ve DTW algoritması [19] kullanılarak dans figürleri tanınmıştır.


Bu çalışma kapsamında, Microsoft Kinect RGBD algılayıcı kullanılarak insan hareketlerinin algılanıp sınıflandırılması amaçlanmıştır. Algılayıcıdan elde edilen veriler kullanılarak, tanınmaya çalışılan insan hareketleri 3 boyutlu olarak modellenmiştir. Yürüme, oturma, el sallama gibi temel insan hareketleri modellenmeye ve tanınmaya çalışılmıştır. Hareketler belirlenirken XMAS [16] veri kümesindeki hareketler baz alınmıştır. Eklemler arası açılar ve eklemlerin yerdeştirmeleri öznelitlik olarak alınıp, Support Vector Machine (SVM) ve Random Forest (RF) yöntemleri ile sınıflandırma yapılmıştır.

## II. YÖNTEM

İlk olarak, Microsoft Kinect RGBD algılayıcıdan elde edilen derinlik haritasından insan eklemlerinin takibinin yapılması gerekmektedir. Bu amaçla Shotton ve diğerleri [3] tarafından gerçekleştirilen eklem-iskelet modeli kullanılmıştır. Shotton ve diğerleri [3], RGBD algılayıcı yardımıyla, vücut eklemlerinin 3 boyutlu konumlarını gerçek zamanlı olarak bulmaktadırlar. Derinlik haritasındaki her piksele ilişkin derinlik ve pozisyon bilgileri kullanılarak öznelitlikler elde edilmiştir. Önceden tanımlanmış derinlik haritaları üzerinde etiketlenmiş vücut kesimlerine ait öznelitlikler kullanılarak RF yöntemi ile eğitilmiştir. Modelde kullanılan 3 ağacın herbiri için yaklaşık 300.000 görüntü kullanılmıştır. Eklemlerin konumlarının tespitinde ilk olarak vücut kesimlerinin tanınması yapılmıştır. Daha sonra eklemlerin bulunması için 2 boyutlu koordinatlar ve derinlik haritası kullanılarak 3 boyutlu koordinatlara dönüşüm yapılmış ve mean-shift [22] algoritması kullanılarak konumlar bulunmuştur. Bu modelden elde edilen 20 eklemlilik insan iskeleti Şekil-1'de görülmektedir.

### A. Veri Kümesi

Yapılan çalışma kapsamında, 4 farklı aktör tarafından 10 farklı harekete ilişkin toplamda 110 hareket verisi elde edilmiştir. XMAS veri kümesi baz alınarak tanımlanan hareket kümesi el sallama, saate bakma, tekme atma, yumruk atma, kolları çapraz yapma, yürüme, kafa kaşıma, yerden birşey alma, çömelme ve kendi ekseninde dönme hareketlerini içermektedir. XMAS [16] veri kümesinde hareketler çoklu kamera düzeneği ile kaydedilmiştir. Bu çalışmada kullanılan veri kümesindeki hareketler ise, Microsoft Kinect RGBD algılayıcı ile kaydedilmiştir.



Şekil-1 Shotton ve diğerlerinin [3] yönteminden elde edilen iskelet modeli

### B. Öznelitlik çıkarma

Veri kümesi oluşturulduktan sonra, öznelitlik olarak ilk etapta eklemlere ilişkin açılar kullanılmıştır. Veri kümesindeki hareketleri tanımak için en uygun açılar olan, omuz- dirsek- kol ve kalça-diz- ayak bileği eklemleri arasındaki açı değerleri, tüm hareket boyunca tutulup, açı değerlerine ilişkin histogramlar oluşturulmuştur. İskelet modelinde kullanılan açılar Şekil-1'de sayılarla gösterilmektedir. Açı değerleri hesaplanırken, her bir açı değerine ait 3 boyutlu koordinat değerleri kullanılmıştır. Bu koordinat değerleri kullanılarak nokta ikilileri doğru parçaları olarak varsayılmış ve bu doğru parçaları arasındaki açı değerleri hesaplanmıştır.

Doğru parçası, 3 boyutlu bir uzayda bir  $P_1$  noktasından  $P_2$  noktasına uzanan bir bölügedir (*segment*). Açılar hesaplanmadan önce açısı bulunacak eklemlere ilişkin nokta ikilileri, doğru parçaları olarak alınmıştır. İki doğru parçası arasındaki açı hesaplanmadan önce, doğru parçalarının yönlü kosinüs (directed cosine) değerlerinin hesaplanması gerekmektedir.  $P_1(x_1, y_1, z_1)$  ve  $P_2(x_2, y_2, z_2)$   $P_1P_2$  doğru parçasını tanımlayan iki nokta olsun.  $P_1P_2$  doğru parçasına ait kosinüs değerleri aşağıdaki gibi verilmektedir.


$$\cos \alpha = \frac{x_2 - x_1}{d} \quad \cos \beta = \frac{y_2 - y_1}{d} \quad \cos \gamma = \frac{z_2 - z_1}{d} \quad (1)$$

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2 + (z_2 - z_1)^2} \quad (2)$$

$\alpha, \beta, \gamma$  sırasıyla x, y ve z eksenindeki eğim değerlerini belirtmektedir. Eşitlik 2 de belirtilen d değeri ise iki nokta arasındaki uzaklığı belirtmektedir. Bu değerlerin ikisi verildiği zaman üçüncüsü Eşitlik 3 ile bulunabilir.

$$\cos^2 \alpha + \cos^2 \beta + \cos^2 \gamma = 1 \quad (3)$$

Bir doğru parçasının yönlü kosinüs bilgilerini,  $\lambda, \mu$  ve  $\nu$  olarak gösterebiliriz. Aynı şekilde bu değerler doğru parçasının x, y, z eksenleri üzerindeki birim vektör izdüşümlerine de karşılık gelmektedir. İlgili birim vektörler Şekil-2'de belirtilmiştir. Bu vektörlerin birleşimi doğru parçasını vermektedir.



Şekil-2 Bir u vektörüne ilişkin birim vektörler [15]

Uzaydaki iki doğru parçası arasındaki açı değeri, bu iki doğru parçası keşişse de kesişmese de bu iki doğru parçasının birim vektörlerinin aralarındaki açılara tekabül etmektedir.  $(\lambda_1, \mu_1, \nu_1)$  ve  $(\lambda_2, \mu_2, \nu_2)$  olarak tanımlanan iki doğru parçası arasındaki  $\Theta$  açısı Eşitlik 4 ile belirtilmektedir.

$$\cos \Theta = \lambda_1 \lambda_2 + \mu_1 \mu_2 + \nu_1 \nu_2 \quad (4)$$

Böylelikle  $\alpha_1, \beta_1, \gamma_1$  ve  $\alpha_2, \beta_2, \gamma_2$  yön açılarına sahip iki doğru arasındaki açı aşağıdaki gibi de verilebilir.

$$\cos \Theta = \cos \alpha_1 \cos \alpha_2 + \cos \beta_1 \cos \beta_2 + \cos \gamma_1 \cos \gamma_2 \quad (5)$$


Şekil-1'de numaralarla belirtilen açıları hesaplamak için ilgili açıyı tanımlayan eklem noktalarına ilişkin koordinat değerleri kullanılmıştır. Her açı,  $P_1P_2P_3$  şeklinde iki bölüme olarak tanımlanmıştır. Yani hesaplanacak her açı ortak noktaya sahip iki doğru parçası olarak ele alınmış ve hareket boyunca her çerçeve için bu açı değeri hesaplanmıştır. Açı değerlerinin hesaplanmasında Eşitlik 5 kullanılmıştır. Her çerçeve için açı değerleri hesaplandıktan sonra bu eklemlerdeki açıların histogramları oluşturulmuştur. Gözlenen 8 eklemin hareket boyunca hangi açılara sahip olduğu

bilgisi, hareketin tanınmasında öz-nitelik olarak kullanılmıştır. Çalışma sürecinde, 10,15,20,25,30 gibi farklı sayıdaki kutulara sahip histogramlar hesaplanmıştır. En iyi sınıflama sonuçlarına 10 kutu ile ulaşıldığı için, bu bildiride sadece 10 kutuya ilişkin sonuçlar verilmiştir. Farklı açı aralıkları kullanılarak oluşturulan histogramlara ilişkin sınıflama doğrulukları Tablo-6'da yer almaktadır.


Her eklem için ayrı ayrı çıkarılan tüm histogramlar birleştirilerek bütünsel bir gösterim elde edilmiştir. Bu işlem, Şekil 1'de verilen açılı sıralaması baz alınarak, tüm eklemlere ilişkin histogramlardaki bilgilerin tek boyutta bir dizi şeklinde peş peşe eklenmesiyle yapılmıştır. Sıra bilgisi önemlidir, çünkü hangi eklemden değişim olduğu bilgisi sınıflama algoritmasının seçiciliğini etkilemektedir.

Şekil-3'te, kolları çapraz yapma hareketine ilişkin açılı histogramları verilmiştir. Şekil-4'te ise, tekme hareketi sırasında ölçülen eklem açılarının histogramları verilmiştir.


Sadece açılı değerleri ile her zaman yeterli sınıflama başarısı ulaşılamamaktadır. Özellikle sıçrama, oturma gibi hareketlerin ayırt edilmesinde açılı değerlerinin yanı sıra, eklem noktalarının yer değiştirme bilgisi de gerekmektedir. Sadece eklem açılı bilgileri kullanılarak elde edilen başarımlar Tablo-1'de verilmiştir. Sadece eklem açıları kullanılarak %80 civarında bir sınıflama başarısı elde edilmiştir. Sınıflandırma başarımını artırmak amacıyla eklemlerin yer değiştirme bilgisi de öz-nitelik olarak kullanılmıştır.



Şekil-3 Kolları çapraz tutma hareketi için histogramlar



Şekil-4 Tekme hareketi için histogramlar



Şekil-5. El sallama sırasında el bileğinin yer değiştirmesi.

Yerdeğiştirme bilgisi hesaplanırken, el ve ayak eklemleri dışındaki tüm noktaların, merkez omuz noktasına göreli koordinatları

hesaplanmıştır. Shotton ve diğerlerinin algoritmasından elde edilen iskelet modelinde, el ve ayaklara karşılık gelen noktalar gürültü sebebiyle, yanlış konumlarda algılanabilirken, el ve ayak bileklerinin konumu daha tutarlı bir şekilde algılanabilmektedir. Bu sorundan etkilenmemek ve daha tutarlı sonuçlar elde edebilmek amacıyla, el ve ayak bileklerinin yer değiştirme bilgisi kullanılmıştır.

Görelî koordinatlar, görelî koordinatı hesaplanacak noktanın koordinat değerlerinin merkez omuz noktasının koordinatlarından çıkarılmasıyla hesaplanmaktadır. Daha sonra tüm eklemlerin ardışık çerçeveler arasındaki görelî koordinat değerleri arasındaki farklara göre, x, y, z eksenlerindeki toplam yer değiştirmeleri hesaplanmıştır. Her üç eksendeki toplam yer değiştirmelerin ayrı hesaplanmasının amacı, eksene göre farklılık gösteren hareketlerin ayrımının yapılabilmesidir. Örneğin el sallama ve yumruk atma düşünülürse, bu iki hareketin ayrımında farklı eksenlerde hareket edilmektedir. Aynı zamanda tüm noktaların toplam yer-değiştirmesi de hesaplanmıştır. El sallama hareketi için el bileğinin aldığı yol Şekil-5'te gösterilmektedir

### III. SINIFLANDIRMA SONUÇLARI

Eklem açılarına ait histogramlar ve eklem yer değiştirme bilgileri öz-nitelik olarak elde edildikten sonra, sınıflama için SVM ve RF yöntemleri kullanılmıştır.

Öncelikle sadece eklem açıları kullanarak sınıflamanın başarısı değerlendirilmiştir. Daha sonra eklem açılarına ek olarak eklemlerin yer değiştirmeleri de öz-nitelik olarak alınıp sınıflama işlemi tekrar yapılmıştır. Sadece eklem açıları kullanılarak yapılan sınıflamaya ilişkin sonuçlar Tablo-1'de; eklem açıları ve yer değiştirme öz-niteliklerinin birlikte kullanılarak yapılan sınıflama sonuçları Tablo-2'de yer almaktadır. CA (Classification Accuracy) doğru sınıflama oranını, AUC (Area Under Curve) ROC eğrisi altında kalan alanı, Sens duyarlılığı (Sensitivity) belirtmektedir. Eşitlik 6 ve 7'de CA, Sens değerlerinin hesaplanmasında kullanılan eşitlikler verilmiştir.

$$CA = \frac{TP+TN}{TP+TN+FP+FN} \quad (6)$$

$$Sens = \frac{TP}{TP+FN} \quad (7)$$

Sınıflandırma işlemi 10-fold cross validation yöntemi kullanılarak gerçekleştirilmiştir. Yukarıdaki sonuçlara göre, RF algoritması %96 sınıflama doğruluğu ile SVM algoritmasına göre daha başarılı bir sonuç vermiştir. Eklem açılarının ve eklem yer değiştirmelerinin öz-nitelik olarak birlikte kullanımı daha başarılı sonuçlar vermektedir.

Sınıflamada hataların en çok hangi sınıflar arasında yapıldığını anlamak amacıyla, oluşan hata matrisleri incelendi. Tüm öz-nitelikler kullanıldığında, SVM sınıflaması sonucu oluşan hata matrisi Tablo-3'de yer almaktadır. Sınıflamada hareketlere ilişkin sınıflar şöyledir: 1-Saate bakma, 2-Kolları çapraz yapma, 3-Tekme atma, 4-Yerden birşey alma, 5-Yumruk atma, 6-Çömelme, 7-Kendi ekseninde dönme, 8-Kafa kaşıma, 9- Yürüme, 10-El sallama

SVM sınıflaması sonucunda hatalar genellikle kolları çapraz yapma ile saate bakma hareketleri arasında gözlemlenmiştir. Kolları çapraz yapma ve saate bakma hareketlerinde, uzuvlar üst üste bindiği (overlapping) için, iskeletin doğru olarak tespit edilememesi bu durumun oluşmasında etkili olmaktadır. Çömelme, kendi ekseninde dönme ve kafa kaşıma hareketlerinde ise gürültü nedeniyle sınıflamada hatalar meydana gelmektedir. Bunlar dışındaki durumlarda sınıflamada başarılı sonuçlar elde edilmiştir.

Tablo-1 Sadece eklem açılarının kullanıldığı sınıflama sonuçları

	CA	Sens	AUC
<b>SVM</b>	0.80	0.99	0.91
<b>RF</b>	0.83	0.98	0.99

Tablo-2 Eklem açılı ve yer değiştirme bilgilerinin kullanıldığı sınıflama sonuçları

	CA	Sens	AUC
<b>SVM</b>	0.85	0.81	0.98
<b>RF</b>	0.96	0.87	0.99

Tablo-3 SVM algoritması ile hareket sınıflama sonuçlarına ilişkin hata matrisi

	1	10	2	3	4	5	6	7	8	9	
1	7	0	4	0	1	0	0	0	0	0	11
10	0	11	0	0	0	0	0	0	0	0	11
2	3	0	8	0	0	0	0	0	0	0	11
3	0	0	0	11	0	0	0	0	0	0	11
4	0	0	0	0	10	1	0	0	0	0	11
5	0	0	0	0	0	11	0	0	0	0	11
6	0	0	0	0	0	0	8	3	0	0	11
7	0	0	0	0	0	0	1	9	1	0	11
8	0	0	0	0	0	0	0	0	9	1	11
9	0	0	0	0	0	0	0	0	1	10	11
10	11	12	11	11	12	11	11	11	11	11	110

Tüm öz nitelikler kullanıldığında, RF sınıflaması için oluşan hata matrisi Tablo-4 de yer almaktadır. Tablo 3 ile karşılaştırıldığında RF algoritması daha iyi sonuçlar vermiş ve kolları çapraz yapma ile saate bakma gibi benzer hareketlerin karıştırılması sorunu azalmıştır.

Tablo-4 RF algoritması ile hareket sınıflama sonuçlarına ilişkin hata matrisi

	1	10	2	3	4	5	6	7	8	9	
1	11	0	0	0	0	0	0	0	0	0	11
10	0	11	0	0	0	0	0	0	0	0	11
2	1	0	10	1	0	0	0	0	0	0	11
3	0	0	0	11	0	0	0	0	0	0	11
4	0	0	0	1	11	0	0	0	0	0	11
5	0	0	0	0	1	11	0	0	0	0	11
6	0	0	0	0	0	0	10	1	0	0	11
7	0	0	0	0	0	0	0	10	1	0	11
8	0	0	0	0	0	0	0	1	10	0	11
9	0	1	0	0	0	0	0	0	1	10	11
12	11	10	11	11	11	11	11	11	12	11	110

Tablo 1-4'te verilen sınıflama sonuçlarında, eklem açılı için 10 kutuluk histogramlar tanımlanarak sınıflama yapılmıştır. Eklem açılı için farklı sayıda kutular içeren histogramlar kullanıldığında sınıflama sonuçlarının nasıl değişeceğini anlamak amacıyla, 10,15,20,25,30 kutuluk histogramlarla sınıflama işlemi tekrarlanmıştır. Farklı histogramlara göre sınıflama sonucu Tablo 5'te verilmiştir.

Tablo-5 Farklı kutu sayılarına sahip histogramlar kullanılarak elde edilen CA değerleri

# Kutu (Bin)	10	15	20	25	30
<b>SVM</b>	0.85	0.82	0.87	0.87	0.86
<b>RF</b>	0.96	0.90	0.92	0.88	0.93

#### IV. SONUÇLAR

Çalışma kapsamında Microsoft Kinect RGBD algılayıcı kullanılarak elde edilen eklem iskelet modeli üzerinde basit hareketler tanınmaya çalışılmıştır. Öz nitelik olarak eklemlerin açılına ilişkin histogramlar ve eklem noktalarının yer değiştirme bilgileri kullanılmıştır. Öz nitelik kümesi elde edildikten sonra, hareketlerin sınıflandırması için SVM ve RF yöntemleri kullanılmıştır. RF ile % 96 oranında sınıflama başarısına ulaşılırken, SVM ile % 85 oranında bir başarı sağlanmıştır.

Bu çalışmanın devamı olarak, ard arda gelen bir dizi hareket tanınmaya çalışılacaktır. Ard arda hareketleri içeren veri, zaman dilimlerine bölünecektir. Zaman dilimleri içerisinde tanınan atomik hareketler, HMM yöntemine girdi olarak verilip ard arda hareketler tanınmaya çalışılacaktır. HMM yöntemine alternatif olarak, atomik hareketler üzerinde ontoloji tanımlanarak karmaşık hareketler tanınmaya da mümkün görünmektedir.

#### KAYNAKÇA

- [1] Sung, J., Ponce, C., Selman, B., Saxena, A. 2011. Human Activity Detection from RGBD Images. AAAI workshop on Pattern, Activity and Intent Recognition,
- [2] Xia, L., Chen, C., Aggarwal, J. K. 2011. Human Detection Using Depth Information by Kinect. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)
- [3] Shotton, J., Fitzgibbon, A., Cook, M., Sharp, T., Finocchio, M., Moore, R., Kipman, A., Blake, A. 2011. Real-Time Human Pose Recognition in Parts from Single Depth Images. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)
- [4] Doliotis, P., Stefan, A., McMurrough, C., Eckhard, C., Athios, V. 2011. Comparing Gesture Recognition Using Color and Depth Information. Conference on Pervasive Technologies Related to Assistive Environments (PETRA)
- [5] Li, W., Zhang, Z., Liu, Z. 2010. Action Recognition Based on A Bag of 3D points. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)
- [6] İnternet: [www.primesense.org](http://www.primesense.org). Son Erişim: 02.02.2012
- [7] Popa, M., Koç, A., K., Rothkrantz L., J., M., Shan, C., Wiggers, P. 2011. Kinect Sensing of Shopping related Actions. Interactive Human Behavior Analysis in Open or Public Spaces Workshop
- [8] Prismall, S., P., 2005. Object reconstruction by moments extended to moving sequences, Phd thesis, Department Electronic and Computer Science, University of Southampton
- [9] Luber, M., Spinello, L., Arras, K., O. 2011. Learning to Detect and Track People in RGBD Data. RGBD-2011 Workshop
- [10] Dalal, N., Triggs, B. 2005. Histograms of oriented gradients for human detection. IEEE Conference on Computer Vision and Pattern Recognition (CVPR).
- [11] Harris, C., Stephens, M. 1988. A combined corner and edge detector. In Alvey Vision Conference. 147-152
- [12] Jolliffe I.T., 2002. Principal Component Analysis, Series: Springer Series in Statistics, 2nd ed., Springer, NY, XXIX, 487 p. 28
- [13] Barrow, H., Tenenbaum, J., Bolles, R. And Wolf, H. 1977. Parametric correspondence and chamfer matching: Two new techniques for image matching. In Int'l Joint Conf. of Artif. Intel., pages 659-663.
- [14] Canny, J. 1986. A Computational Approach To Edge Detection, IEEE Trans. Pattern Analysis and Machine Intelligence, 8(6):679-698
- [15] Artin, M.1991. Algebra, Prentice Hall, ISBN 978-0-89871-510-1
- [16] İnternet: <http://4drepository.inrialpes.fr/public/viewgroup/6>, Son Erişim Tarihi: 04.02.2012
- [17] Lars Juhl Jensen and Alex Bateman, 2011. The rise and fall of supervised machine learning techniques, Bioinformatic Vol. 27 24 pages 2331-3332
- [18] Raptis, M., Kirovski, D., Hoppe, H. Real-Time Classification of Dance Gestures from Skeleton Animation, Eurographics/ ACM SIGGRAPH Symposium on Computer Animation, 2011.
- [19] Rabiner, L., R., Juang, B. 1993. Fundamentals of speech recognition. Prentice-Hall, Inc.
- [20] Alpaydm, E., 2011. Introduction to Machine Learning, MIT Press, ISBN 0-262-01211-1
- [21] Ludmila I., Zliobaite, K., I., 2008. Linear Discriminant Classifier (LDC) for Streaming Data with Concept Drift. In Proceedings of the 2008 Joint IAPR International Workshop on Structural, Syntactic, and Statistical Pattern Recognition (SSPR \& SPR '08)
- [22] Comaniciu, D., Meer, P. 2002. Mean shift: A robust approach toward feature space analysis. IEEE Trans. PAMI, 24(5)